Introducción al Aprendizaje No Supervisado

Aprendizaje No Supervisado · Sesión 0: Fundamentos

UDEM Jorge Alberto Ramírez García, M.Eng.

Supervisado vs no supervisado

Aprendizaje supervisado

- La respuesta deseada **existe**
- Clasificación: ¿fallará la máquina?
- Regresión: ¿cuánto costará?

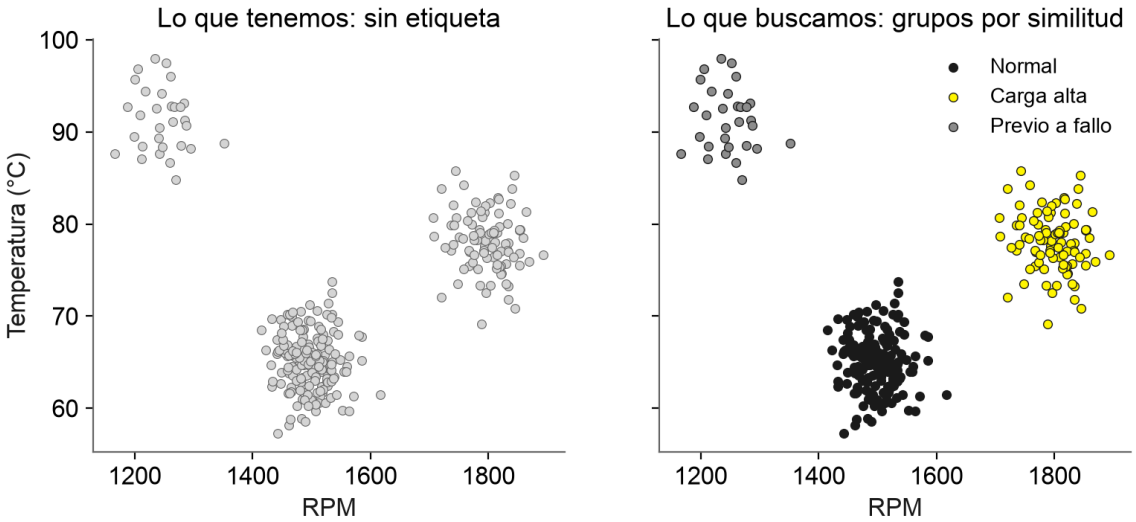
Aprendizaje no supervisado

- La respuesta deseada **no existe**
- Agrupamiento: ¿qué tipos de operación hay?
- Reducción de dimensionalidad: ¿cómo resumo 20 sensores?

Turno	RPM	Temp (°C)	Corriente (A)	Fallo
Mañana	1510	64	12.1	No
Tarde	1240	93	19.4	Sí
Noche	1820	77	15.9	No

Si nadie anotó la columna **Fallo**, sólo quedan las lecturas: el problema se vuelve **no supervisado**.

Clustering: agrupar por similitud



La idea

- Asignar una **etiqueta** a cada observación según su similitud
- No necesita etiquetas previas
- Sirve para encontrar **patrones** en los datos

¿Qué lo hace difícil? Normalmente hay que **definir el número de grupos** de antemano… y decidir qué significa "parecido".

Familias de algoritmos de clustering

Por centroides

- **K-Means**
- Grupos redondos alrededor de un centro
- Tú eliges k
- **Sesión 1**

Jerárquico

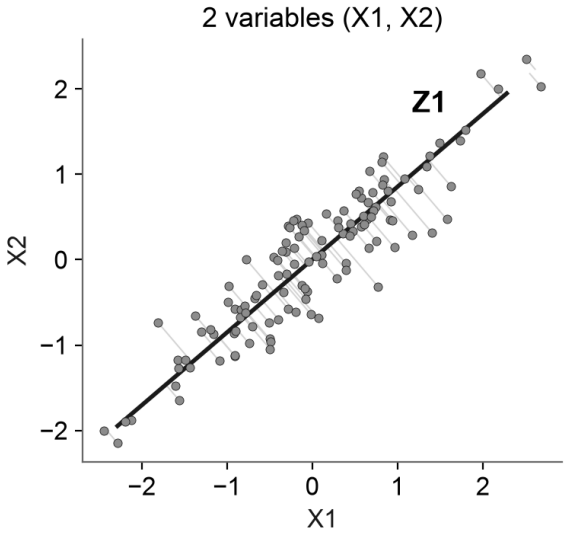
- Árbol de fusiones (dendrograma)
- Familia muy conocida
- No forma parte de este curso

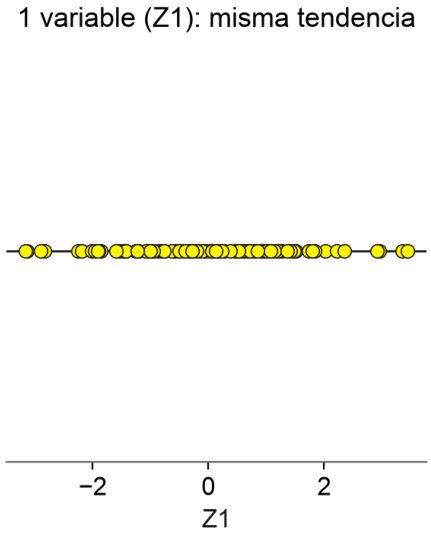
Por densidad

- **DBSCAN**
- Grupos de cualquier forma
- Marca el **ruido** (atípicos)
- **Sesión 2**

Complejidad creciente: de "tú eliges k y todos los puntos pertenecen a un grupo" (K-Means) a "el algoritmo decide cuántos grupos hay y quién no encaja en ninguno" (DBSCAN).

Reducción de dimensionalidad



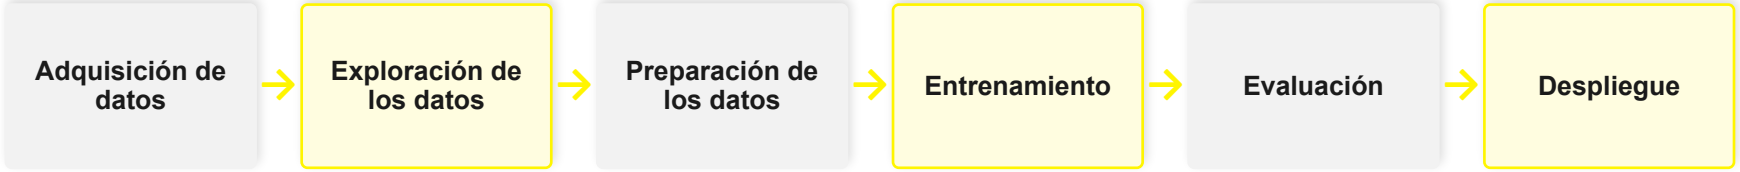


La idea

- Reducir información **conservando la tendencia** de interés
- Tampoco necesita etiquetas
- Visualizar datos complejos en 2D/3D
- Paso de **preprocesamiento**

$X_1, X_2 \rightarrow Z_1$ (PCA: sesión 3)

Flujo de trabajo



Preparación

- **Escalar** siempre
- Log en montos sesgados
- Elegir qué variables entran

Entrenamiento

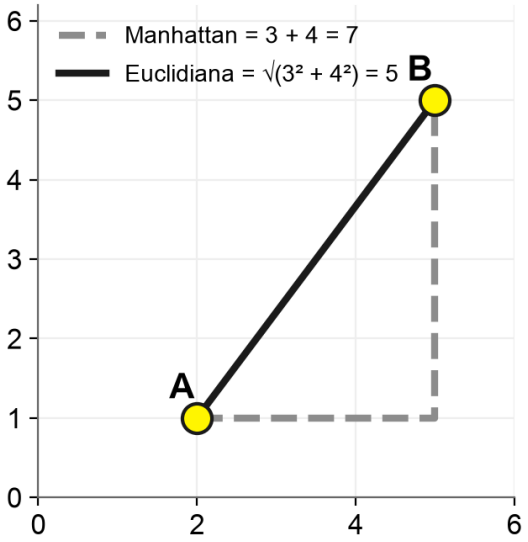
- K-Means, DBSCAN, PCA
- Elegir k, ε, componentes
- Semilla fija (random_state)

Evaluación

- **No hay** respuesta para comparar
- Métricas internas
- Sentido de negocio: ¿a cada grupo le toca una acción?

Distancias: ¿qué tan parecidos son?

Distancia	Fórmula	Úsala cuando…
Euclidiana	$\sqrt{\Sigma (p_i - q_i)^2}$	Medidas numéricas (default)
Manhattan	$\Sigma \lvert p_i - q_i \rvert$	Te mueves "por cuadras"
Coseno	$1 - p \cdot q / (\lVert p \rVert \lVert q \rVert)$	Importan proporciones (canastas, textos)
Haversine	$2R \cdot \arcsin \sqrt{\sin^2(\Delta\phi/2) + \cos\phi_1 \cos\phi_2 \sin^2(\Delta\lambda/2)}$	Coordenadas GPS (en radianes)



UDEM → Macroplaza: Haversine = 11.05 km · euclidiana en grados × 111 ≈ 12.22 km ✗

Por qué escalar

Persona	Edad	Salario
1	45 años	$50,000
2	30 años	$75,000

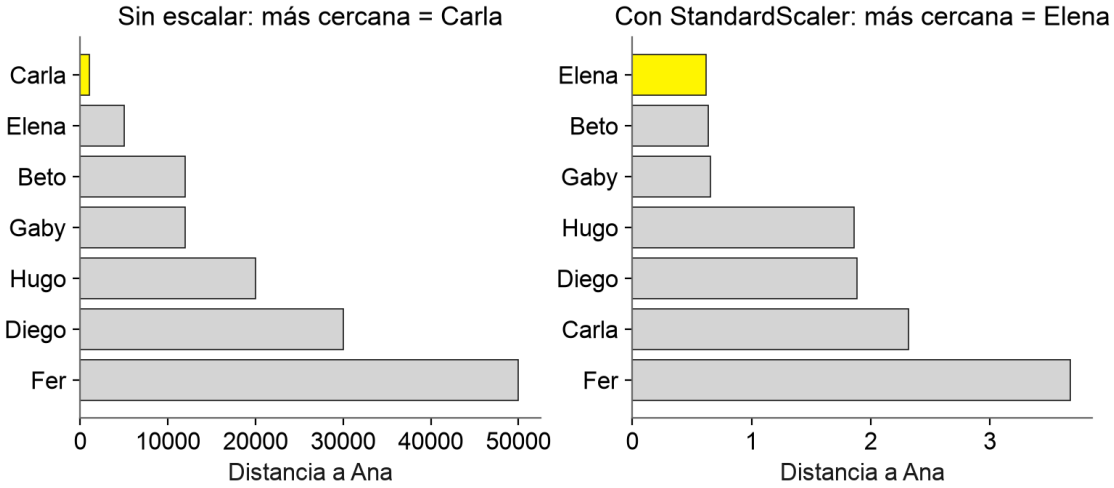
Sin escalar: distancia = **25,000.0045**. Los 15 años de diferencia aportan sólo **0.0045**.

Con Min-Max: (1, 0) y (0, 1) → distancia = **1.4142**. Edad y salario pesan lo mismo.

La lección

- Las distancias suman diferencias de **todas** las variables
- La variable con unidades más grandes **manda**
- Medir el salario en miles cambiaría el resultado
- Escalar = que el análisis no dependa de las unidades
- En este curso **siempre** escalamos antes de K-Means, DBSCAN o PCA

StandardScaler vs MinMaxScaler



StandardScaler

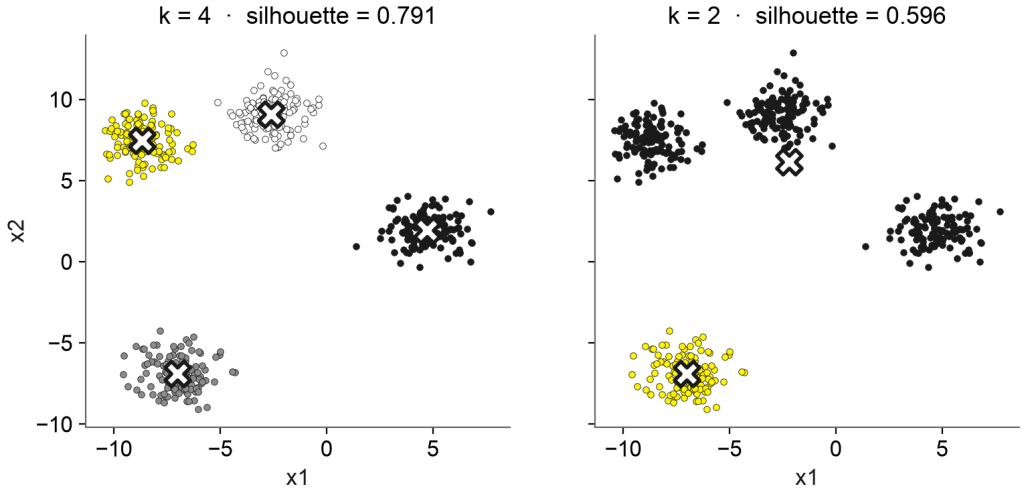
- $z = (x - \mu) / \sigma$
- Media 0, desviación 1
- **Default** del curso

MinMaxScaler

- $x' = (x - \text{mín}) / (\text{máx} - \text{mín})$
- Todo entre 0 y 1
- Un atípico aplasta al resto

Sin escalar, la persona más parecida a Ana (25 años) es Carla (58 años), sólo porque ganan casi lo mismo.

¿Cómo se evalúa algo sin etiquetas?



Métrica	Mejor
Silhouette	↑ (de −1 a 1)
Davies-Bouldin	↓ (0 es ideal)
Calinski-Harabasz	↑ (sin tope)
ARI (con etiqueta)	↑ (1 = perfecto)

Las internas usan sólo X; el ARI necesita la etiqueta real, que en la práctica no existe.

$s(i) = (b(i) - a(i)) / \max\{a(i), b(i)\}$ **a: a su grupo · b: al grupo vecino**

Caso de estudio: minería (Caterpillar)

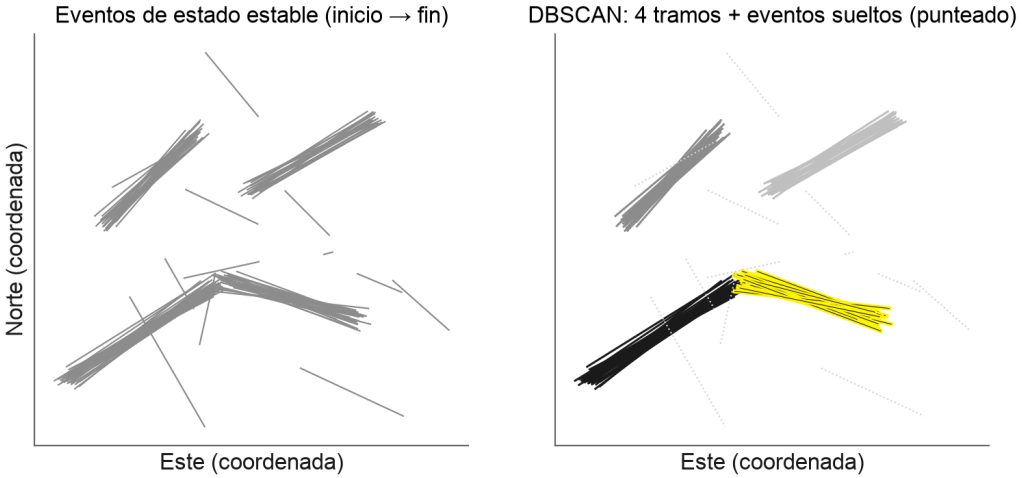


Ilustración con datos sintéticos.

1. **Definir "estado estable"**
   Con carga, de subida sin variación de grado, velocidad estable
2. **Extraer y particionar**
   Todos los datos → tabla de estadísticos por evento
3. **Mapear inicio y fin**
   Cada evento es una línea recta sobre el mapa de la mina
4. **DBSCAN**
   Separa los tramos más transitados, incluso los muy cercanos

Pregunta: ¿cuál es el tramo más transitado de la mina, para comparar cada máquina en las mismas condiciones?

Mapa del curso

Sesión	Tema	Caso	Pregunta
0	Fundamentos	—	Distancias, escalado y métricas
1	K-Means	Mall Customers	¿Qué segmentos de clientes hay y qué campaña le toca a cada uno?
2	DBSCAN	Mall + entregas GPS en Monterrey	¿Qué clientes no encajan? ¿Dónde poner centros de distribución?
3	PCA	Vinos (Wine)	¿Cuántas medidas químicas necesitamos para distinguir los vinos?
4	Caso integrador	Clientes mayoristas (UCI)	¿Cómo organizar a los clientes? (escalado → PCA → K-Means vs DBSCAN)

Conclusiones

1. No supervisado = la respuesta deseada no existe: agrupamos y reducimos dimensiones
2. Parecido = cerca: euclidiana, Manhattan, coseno o Haversine según la pregunta
3. Escalar no es opcional: sin escalar, manda la variable con unidades más grandes
4. Sin etiquetas evaluamos compacidad y separación: silhouette ↑, Davies-Bouldin ↓, Calinski-Harabasz ↑
5. Ninguna métrica sustituye al sentido de negocio