Caso Integrador:
De los datos a la decisión

Aprendizaje No Supervisado

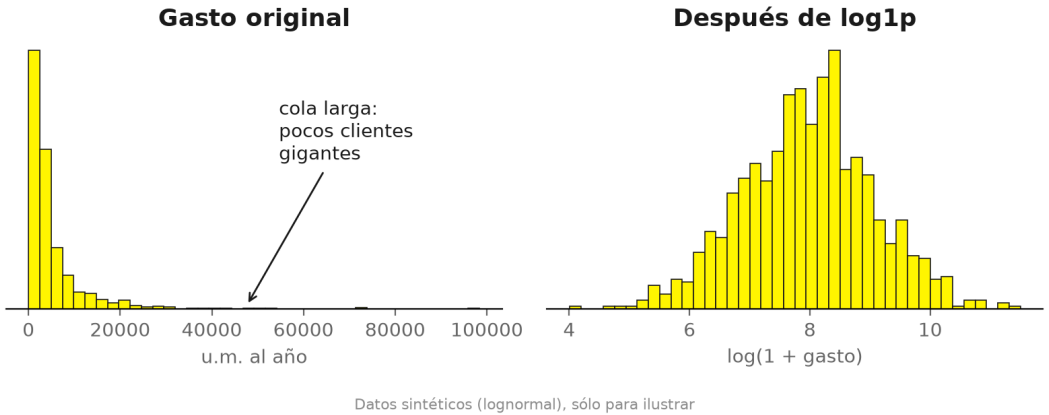
UDEM Jorge Alberto Ramírez García, M.Eng.

El flujo de un proyecto no supervisado

Preparar	Reducir	Agrupar	Validar	Interpretar	Actuar
• Nulos y tipos • Transformar (log1p) • Escalar	• PCA • Scree y cargas • Ejes con nombre	• K-Means: segmentos • DBSCAN: atípicos	• Métricas internas • ARI si hay etiqueta • Estabilidad	• Perfil en unidades originales • Nombre por segmento	• Una acción por segmento • Plan para atípicos

No es una línea recta: si el perfil no tiene sentido de negocio, regresa a preparar o a elegir otro k. **El entregable no es un cluster: es una decisión.**

Preparar: transformar antes de escalar



Datos sintéticos (lognormal), sólo para ilustrar

¿Cuándo log1p?

- Montos de dinero, conteos, tiempos
- Media ≫ mediana
- Asimetría > 1
- Máximo decenas de veces la mediana
- Con ceros: log1p, no log

$x' = \log(1 + x)$ → después StandardScaler

Checklist de decisiones

Decisión	Herramienta	Regla práctica
¿Escalar?	StandardScaler	Siempre con K-Means, DBSCAN y PCA
¿Transformar?	np.log1p	Si hay sesgo fuerte y outliers enormes
n_componentes	Scree plot + cargas	Codo o 80-90% de varianza; que se puedan nombrar
k (K-Means)	Codo + silhouette, DB, CH	Varias señales + sentido de negocio
min_samples	Dimensiones	≈ 2 × número de dimensiones
eps (DBSCAN)	Gráfica de k-distancia	Justo antes de que la curva se dispare
¿Qué entra?	Lista de columnas	Nunca la etiqueta que usarás para validar

K-Means vs DBSCAN vs PCA

	K-Means	DBSCAN	PCA
Para qué	Segmentar en k grupos	Zonas densas + atípicos	Reducir y visualizar
Tú eliges	k	eps y min_samples	n_componentes
Forma de grupos	Esféricos, tamaños parecidos	Cualquier forma	No agrupa
Outliers	Los fuerza a un cluster	Los marca como ruido (-1)	Pueden dominar un eje
Úsalo cuando	Quieres segmentos accionables	Buscas anomalías o formas raras	Hay muchas variables correlacionadas
Cuidado con	Elegir k con una sola métrica	eps al azar; densidades variables	No escalar; no leer cargas

En la práctica se **combinan**: PCA para preparar el espacio, K-Means para segmentar y DBSCAN para vigilar.

Validar e interpretar

Métricas internas

- Silhouette ↑, Davies-Bouldin ↓, Calinski-Harabasz ↑
- Sólo comparables en el mismo espacio
- Sin contar el ruido

Etiqueta externa

- ARI contra una variable que NO usaste
- No buscas copiarla: buscas que la explique
- En la vida real casi nunca existe

Perfil de negocio

- Promedios y medianas en unidades originales
- Tamaño y % del total
- Un nombre y una acción por segmento

Cluster → perfil → nombre → acción

Errores comunes

✗ Agrupar sin escalar	✓ Escala siempre; con dinero, log1p y luego escala
✗ Creer en una silhouette alta sin ver los tamaños	✓ Revisa cuántos puntos tiene cada cluster
✗ Comparar métricas de espacios distintos	✓ Compara en el mismo espacio o usa ARI
✗ Meter la etiqueta (o los clusters) como variable	✓ Deja fuera lo que usarás para validar
✗ Reportar centroides escalados o en PCs	✓ Perfila sobre el df original
✗ Terminar en 'encontré 3 clusters'	✓ Termina en una decisión por segmento

El caso: un distribuidor mayorista

Contexto

- 440 clientes de un mayorista en Portugal
- Gasto anual en 6 categorías: frescos, lácteos, abarrotes, congelados, detergentes y papel, delicatessen
- Además: canal (Horeca o Retail) y región
- Fuente: UCI ML Repository (CC BY 4.0)

Tu misión

- Agrupar sólo con los 6 gastos
- Canal y región quedan fuera del modelo
- Usar el canal al final para validar
- Proponer equipo de venta, surtido y logística por segmento

¿Cómo debe organizar el distribuidor a sus clientes mayoristas?

Rúbrica sugerida de entrega

Criterio	Qué se espera	Peso
Preparación	Exploración, justificación de log1p y escalado	15%
Reducción	n_componentes justificado; ejes interpretados con las cargas	15%
Agrupamiento	k elegido con varias métricas + negocio; DBSCAN con k-distancia	20%
Validación	Métricas en el mismo espacio, tabla cruzada y ARI bien interpretados	15%
Interpretación	Perfil en unidades originales y nombre de cada segmento	15%
Recomendaciones	Acción concreta por segmento y plan para atípicos	15%
Comunicación	Notebook limpio, ejecutable de principio a fin	5%

Conclusiones del curso

1. Prepara bien: escalar (y transformar) cambia los resultados más que el algoritmo
2. PCA resume y permite ver; nombra cada componente con sus cargas
3. K-Means segmenta, DBSCAN detecta atípicos: se complementan
4. Elige k, eps y componentes con varias señales y con criterio de negocio
5. Un cluster vale lo que vale la decisión que permite tomar